

```
drivers<-read.csv("./data/Drivers.csv", header = T, sep = ",")
fit.full<-glm(y~x1+x2+x3, data=drivers, family=binomial)
summary(fit.full)
```

系数估计与显著性检验

```
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  0.59761    0.89483   0.668   0.5042
## x1          -1.49608    0.70486  -2.123   0.0338 * 拟合里显著
## x2           -0.00160    0.01676  -0.095   0.9242
## x3           0.31587    0.70109   0.451   0.6523
```

Estimate: 系数的估计值

能写出回归方程: $\text{logit}(p) = 0.5976 - 1.4961 \times x_1 - 0.0016 \times x_2 + 0.3159 \times x_3$

Std. Error: 系数的标准误, 衡量估计的不确定性, 越小越精确

z value: 检验统计量 = Estimate / Std. Error, 用于检验该系数是否为0

Pr(>|z|): p值, < 0.05 → 该变量显著; 这里 x1 显著 (*), x2 x3 不显著

模型整体评估 (逻辑回归)

```
## Null deviance: 62.183 on 44 degrees of freedom
## Residual deviance: 57.026 on 41 degrees of freedom
## AIC: 65.026
```

Null deviance: 仅截距模型的偏差, 作为比较基准

Residual deviance: 当前模型的偏差, 越小越好, 表示拟合越好

Deviance 减少量: Null - Residual, 检验模型整体显著性

AIC: 赤池信息准则, 越小模型越好, 用于模型比较

整体显著性检验:

```
1 - pchisq(62.183 - 57.026, df = 44 - 41) # 卡方检验: 模型是否有意义, 结果>0.05?
```

模型整体不显著

```
# =====
# =====
```

线性回归 ANOVA

```
anova(model)
```

```
data(chickwts)
```

```
head(chickwts)
```

```
# 拟合线性回归模型 (等价于ANOVA)
```

```
model <- lm(weight ~ feed, data = chickwts)
```

```
anova(model)
```

线性回归的 ANOVA 表

```
## Analysis of Variance Table
##
## Response: weight
##              Df Sum Sq Mean Sq F value    Pr(>F)
## feed           5  231129    46226  15.365 5.936e-10 ***
## Residuals     65  195556     3009
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Sum Sq: 平方和 (组间/组内)

Mean Sq: 均方 = Sum Sq / Df

F value: F统计量 = 组间均方 / 组内均方

Pr(>F): p值, < 0.05 则表示至少有一组与其他组不同 (决定是否拒绝“所有组均值相等”的原假设)

结论

p = 5.94e-10 < 0.05 → 拒绝原假设 (几个mu全部相同) → 至少有一种饲料与其他饲料的增重效果不同

```
# =====  
=====
```

线性回归的 summary() 输出

```
## Residuals:  
##      Min       1Q   Median       3Q      Max  
## -5.6635 -1.4635  0.0254  1.3476  7.6478  
##  
## Coefficients:  
##              Estimate Std. Error t value Pr(>|t|)  
## (Intercept)  34.1167      1.3590   25.10  <2e-16 ***  
## dheight      0.4445      0.0213   20.87  <2e-16 ***  
##  
## Residual standard error: 2.053 on 1373 degrees of freedom  
## Multiple R-squared:  0.2408,    Adjusted R-squared:  0.2402  
## F-statistic: 435.5 on 1 and 1373 DF,  p-value: < 2.2e-16
```

Residuals: 中位数应该接近 0, 对称分布

残差的最小 1/4分位 中位数 3/4分位 最大

t value: 系数的 t 统计量, 绝对值 > 2 通常显著

Pr(>|t|): p 值, < 0.05 显著

Residual standard error: 残差标准差, 越小拟合越好

Multiple R-squared: 决定系数, 模型解释了多少变异 (0~1), 只适用于线性回归, 逻辑回归没有这个指标

Adjusted R-squared: 调整后 R², 惩罚变量个数, 用于模型比较

F-statistic & p-value: 模型整体显著性, p < 0.05 说明模型有意义

```
# =====  
=====
```

泊松回归

```
glm(.., family = poisson,)
```

```
library(alr4)  
data(AMSSurvey)  
head(AMSSurvey)
```

```
model <- glm(count ~ type + sex + citizen, family = poisson, data = AMSSurvey)  
summary(model)
```

拟合包含交互项的泊松回归 (更复杂的模型)

```
model_saturated <- glm(count ~ type * sex * citizen, family = poisson, data =  
  AMSSurvey)  
summary(model_saturated)
```

查看偏差和自由度

```
summary(model_full)$null.deviance      # Null deviance
```

仅包含截距的模型 (空模型) 的偏差 (基准)

```
summary(model_full)$deviance           # Residual deviance 当前包含所有自变量的模型的偏差
```

```
summary(model_full)$df.null             # Null df = n - 1 (样本量减1)
```

```
summary(model_full)$df.residual         # Residual df = n - p - 1 (样本量减参数个数减1) !
```

拟合优度检验

```
p_value <- 1 - pchisq(deviance(model_full), df.residual(model_full))
p_value
```

判断: $p > 0.05$ 说明模型拟合良好, Residual Deviance 越小越好

Null deviance: 只有截距时, 模型无法解释的变异总量 (相当于线性回归中的 SST)

Residual deviance: 加入所有自变量后, 仍然无法解释的变异 (相当于线性回归中的 SSE)

两者的差值: 模型解释的变异量 (相当于线性回归中的 SSR)

检查模型整体显著性 (似然比检验), $p < 0.05$ 说明模型整体显著 (至少有一个自变量有效)

```
1 - pchisq(summary(model_full)$null.deviance - summary(model_full)$deviance,
           df = summary(model_full)$df.null - summary(model_full)$df.residual)
```

检查拟合优度 (模型是否合适), $p > 0.05$ 说明模型拟合良好 (残差偏差与自由度匹配)

```
1 - pchisq(summary(model_full)$deviance,
           df = summary(model_full)$df.residual)
```

泊松回归输出

```
## Null deviance: 521.4440 on 23 degrees of freedom
## Residual deviance: 1.9568 on 6 degrees of freedom
## AIC: 175.35
```

Null deviance: 521.444 on 23 df $\leftarrow$ 空模型: 偏差很大

Residual deviance: 1.957 on 6 df $\leftarrow$ 当前模型: 偏差大幅减小

残差偏差 $\approx$ 自由度 $\rightarrow$ 拟合良好

检验拟合优度

```
1 - pchisq(1.9568, df = 6) # 0.9236 > 0.05, 模型拟合良好
```

```
# =====
# =====
```

GAM (广义可加模型)

```
library(mgcv); library(alr4); data(pisa); head(pisa)
```

拟合广义可加模型 (GAM)

对 Income Edu Health 三个变量使用样条平滑

```
gam_model <- gam(Overall ~ s(Income) + s(Edu) + s(Health), data = pisa)
```

```
summary(gam_model)
```

```
## Approximate significance of smooth terms:
##      edf Ref.df      F  p-value
## s(Income) 7.593  8.415 8.826 1.29e-06 ***
## s(Edu)     6.204  7.177 3.308 0.00771 **
## s(Health) 1.000  1.000 2.736 0.10679
##
## R-sq.(adj) = 0.863 Deviance explained = 90.3%
```

s(Income) edf = 7.593 远大于1, 说明非线性关系很强 (曲线很弯曲)

(Income) p-value = 1.29e-06 ***, 极其显著, Income 对 Overall 有明显非线性影响

GAM 通过 s() 函数对变量进行非线性平滑拟合

edf: 有效自由度 (平滑程度), 越大说明曲线越弯曲 (非线性越强)

Ref.df: 参考自由度

F / p-value: 该平滑项是否显著 (判断该变量是否显著)

Deviance explained: 模型解释的偏差比例 (类似 R^2 , 和 $R\text{-sq.}(adj)$ 评估整体拟合优度)

```
# =====  
=====
```

Lasso 回归

```
library(glmnet); set.seed(123)
```

```
# 生成自变量 X (标准正态分布)
```

```
n <- 100
```

```
p <- 10
```

```
X <- matrix(rnorm(n * p), nrow = n, ncol = p)
```

```
# 设置真实的系数: 只有前3个变量有影响, 其余为0
```

```
beta <- c(1.2, -0.8, 0.5, rep(0, p - 3))
```

```
# 生成因变量 Y (加噪声)
```

```
Y <- X %*% beta + rnorm(n, sd = 0.5)
```

```
# 交叉验证选择最优 lambda
```

```
cv_lasso <- cv.glmnet(X, Y, alpha = 1) # alpha=1 表示 Lasso
```

```
# 查看最优 lambda
```

```
cv_lasso$lambda.min # 使交叉验证误差最小的 $\lambda$ ,  $\lambda$ 越大压缩越强  $\rightarrow$  更多系数被压缩为 0  $\rightarrow$   
模型更简单
```

```
cv_lasso$lambda.1se # 最稀疏的 $\lambda$  (误差在1个标准误内)
```

```
# 拟合完整 Lasso 路径
```

```
lasso_model <- glmnet(X, Y, alpha = 1)
```

```
# 提取 lambda.1se 对应的系数
```

```
coef(lasso_model, s = cv_lasso$lambda.1se)
```

Lasso 回归系数输出:

```
coef(obj, s = obj.cv$lambda.1se)
```

```
## 4 x 1 sparse Matrix
```

```
## (Intercept) 0.089
```

```
## X1 0.923 # 被选中
```

```
## X2 0.846 # 被选中
```

```
## X3 . # 被压缩为 0, 剔除
```

```
## > cv_lasso$lambda.min
```

```
## [1] 0.05423167 # 较小  $\rightarrow$  模型较复杂, 预测误差最小
```

```
## > cv_lasso$lambda.1se
```

```
## [1] 0.1523456 # 较大  $\rightarrow$  模型更简单, 但预测误差在1个标准误内
```

```
## > coef(lasso_model, s = cv_lasso$lambda.1se)
```

```
## 11 x 1 sparse Matrix of class "dgCMatrix"
```

```
s1
```

```
## (Intercept) 0.023456789
```

```
## V1 1.156789012
```

```
## V2 -0.745678901
```

```
## V3 0.423456789
```

```
## V4 .
```

```
## V5 .
```

```
## V6 .
```

```
## V7 .
```

```
## V8 .
```

```
## V9 .
```

```
## V10 .
```

```
# 二分类问题
```

```

Y_binary <- ifelse(Y > median(Y), 1, 0)
# 交叉验证 (用 family="binomial")
cv_lasso_logit <- cv.glmnet(X, Y_binary, alpha = 1, family = "binomial")
# 提取系数
coef_logit <- coef(cv_lasso_logit, s = "lambda.1se")
coef_logit[coef_logit != 0, ]

# =====
# =====

```

聚类/降维

```

data(USArrests); head(USArrests)
# 数据标准化 (PCA 前必须做, 因为变量单位不同)
df_scaled <- scale(USArrests)
# PCA
pca_result <- prcomp(df_scaled, center = TRUE, scale. = TRUE)
# 方差解释率表
summary(pca_result)

```

```

## Importance of components:
##
##              Comp.1      Comp.2      Comp.3
## Standard deviation  5.133350  4.144921  3.655005
## Proportion of Variance 0.055593  0.036246  0.028184
## Cumulative Proportion 0.055593  0.091839  0.120022

```

Standard deviation: 特征值的平方根

Proportion of Variance: 单个主成分解释的方差比例

Cumulative Proportion: 累积解释比例 (选择保留多少PC的依据)

```

# =====
# =====

```

方差齐性检验 - 检验线性回归模型的【残差】是否满足方差齐性假设

```
ncvTest(model)
```

先拟合一个线性回归模型

```

model <- lm(y ~ x1 + x2, data = mydata)
# 然后用 ncvTest() 检验方差齐性, p<0.05 表示存在异方差
library(car)
ncvTest(model)

```

```

# Non-constant Variance Score Test
# Variance formula: ~ fitted.values
# Chisquare = 12.34567      Df = 1      p = 0.00044

```

$p < 0.05$ → 拒绝原假设 (方差齐) → 存在异方差

$p \geq 0.05$ → 不拒绝原假设 → 方差齐性成立

```
plot(model, which = 1) # 残差vs拟合值图, 点随机分布对应 $p \geq 0.05$ , 方差齐性
```

```

#####
s1 <- lm(Y ~ ., sniffer)
ncvTest(s1) # 默认基于拟合值
ncvTest(s1, ~ TankTemp + GasTemp) # 指定变量

```

基于拟合值

```

## Non-constant Variance Score Test
## Chisquare = 4.802652, Df = 1, p = 0.028416

```

```
# 基于指定变量
## Chisquare = 9.83621, Df = 2, p = 0.007313

p < 0.05 → 存在异方差，需要加权最小二乘法或变换因变量
```

```
# =====
# =====
```

```
残差诊断图 (Residual Plots)
obj <- lm(dheight ~ mheight, data = Heights)
residualPlots(obj)

plot(lm_model)
```

依次检查

残差 vs 拟合值：是否有非线性趋势或异方差
 Q-Q 图：残差是否正态（点应接近直线）
 Scale-Location：方差齐性（水平线最好）
 残差 vs 杠杆值：是否有强影响点

```
# =====
```

```
异常值检测 (Outlier Test)
obj <- lm(lpres ~ bp, data = Forbes)
outlierTest(obj)
```

```
##          rstudent  unadjusted p-value  Bonferroni p
##  12  12.40691          6.0892e-09    1.0352e-07
```

第12个观测点是异常值（学生化残差极大，Bonferroni校正后 $p < 0.05$ ）
 处理方式：删除后重新拟合 (Forbes1 = Forbes[-12,])

异常值/强影响点

```
outlierTest(model)          # 输出异常点的编号和p值
influenceIndexPlot(model) # 强影响点可视化
```

```
##          Test stat Pr(>|Test stat|)
## mheight      0.1458      0.8841
## Tukey test    0.1458      0.8841
```

Test stat: 检验统计量

Pr(>|Test stat|): p值

p > 0.05 → 没有证据表明存在非线性或异方差（好）

p < 0.05 → 存在非线性关系，考虑对变量做变换

如果 ## Tukey test 5.4198 5.966e-08 ***

p < 0.05 → 拒绝线性假设，说明模型缺少非线性项或交互项

强影响点诊断 (Influence Index Plot)

```
influenceIndexPlot(obj)
```

输出四张图

Cook's distance: 衡量每个点对系数估计的影响, > 1 → 强影响点

hat values: 杠杆值 (高杠杆点) > $2p/n$ → 高杠杆点

studentized residuals: 学生化残差 (异常值) > 2 → 可能的异常值

Cook's dist vs hat: 综合图

```
# =====
# =====
```

分类模型混淆矩阵

```
table(predicted, actual)
##           actual
## predicted Pass Fail
##      Pass  420   23
##      Fail   20    8
```

```
accuracy <- (420 + 8) / (420 + 23 + 20 + 8) # 0.908
```

```
# =====
# =====
```

Box-Cox变换 (Power Transform + Inverse Response Plot)

场景：找出自变量需要做什么变换

输入1: powerTransform (对多个自变量)

```
Highway$sigs1 <- with(Highway, (sigs * len + 1)/len)
pT <- powerTransform(cbind(len, adt, trks, shld, sigs1) ~ 1, Highway)
summary(pT)
```

输出1:

```
##      Est Power Rounded Pwr Wald Lwr Bnd Wald Upr Bnd
## len      0.1437          0    -0.2732      0.5607
## adt      0.0509          0    -0.1854      0.2872
## trks     -0.7028          0    -1.9134      0.5078
## shld      1.3456          1     0.6341      2.0570
## sigs1     -0.2408          0    -0.5341      0.0525
```

Rounded Pwr 列：建议的变换

0 → 对数变换 $\log(x)$; 0.5 → 平方根变换 $\sqrt{x}$

1 → 不变换; -1 → 倒数变换 $1/x$

输入2: inverseResponsePlot (对因变量)

```
inverseResponsePlot(m2)
```

输出2:

```
##      lambda      RSS
## 1  0.1197427 32.32520
## 2 -1.0000000 35.70143
## 3  0.0000000 32.36532
## 4  1.0000000 34.24662
```

第1行是最优lambda (≈ 0.12)，接近0 → 建议对因变量做对数变换

对比RSS: lambda=0时RSS=32.365, lambda=1时RSS=34.247, log变换更好

散点图与变换 (scatterplot + invTranPlot)

```
scatterplot(BrainWt ~ BodyWt, brains, id = TRUE) # 找出异常点
scatterplot(log(BrainWt) ~ log(BodyWt), brains) # 对数变换后线性关系更好
```

```
plot(Height ~ Dbh, ufcwc)
invTranPlot(ufcwc$Dbh, ufcwc$Height) # 找最优变换
```

```
##      lambda      RSS
## 1  0.04787804 152122.8
## 2 -1.00000000 197352.2
```

```
## 3 0.00000000 152232.3
## 4 1.00000000 193739.7
```

最优lambda $\approx$ 0.05, 接近0 $\rightarrow$ 建议 log(Dbh)

QQ图 (正态性检验)

```
m2 <- lm(fertility ~ log(ppgdp), UN11)
qqPlot(m2, id = TRUE)
```

```
## Equatorial Guinea      Zambia
##                   58      198
```

图中标注的点是偏离正态最严重的观测,可用于识别需要进一步检查的异常值

```
# =====
# =====
```

完整流程

拟合初始模型

```
model <- lm(y ~ x1 + x2, data = df)
```

残差诊断

```
residualPlots(model)      # 检查非线性和交互项需求
```

异常值检测

```
outlierTest(model)        # 找出异常点
```

```
influenceIndexPlot(model) # 找出强影响点
```

方差齐性

```
ncvTest(model)           # 检查异方差
```

如果需要变换

```
inverseResponsePlot(model)      # 找因变量变换
```

```
powerTransform(~ x1 + x2, data = df) # 找自变量变换
```

改进模型

```
model2 <- lm(log(y) ~ log(x1) + sqrt(x2), data = df)
```

验证改进

```
residualPlots(model2)      # 应得到改善
```

```
# =====
# =====
```

输出速查

输出	为什么关键	p<0.05 意味着
residualPlots 的 Pr(> Test stat)	每个变量的线性假设	该变量需要非线性项
residualPlots 的 Tukey test	整体线性假设	模型缺少交互项或非线性项
ncvTest	方差齐性	存在异方差
outlierTest 的 Bonferroni p	异常值	该点是异常值
influenceIndexPlot	Cook's distance	>1 的点是强影响点
powerTransform 的 Rounded Pwr	自变量变换	0=log, 0.5=sqrt, 1=不变
inverseResponsePlot	因变量变换	lambda接近0时用log 接近1时不变
qqPlot	正态性	标出的点偏离正态