

统计例题和知识点 (2026.06.03)

事件、概率、古典概型:

例: 52 张的标准扑克牌里面随机抽 2 张, 问全是黑桃的概率

解: $P(B)$ = 事件 B 包含的事件数量/基本事件总数, 52 张抽出 2 张为基本事件数, 事件包含 13 张黑桃里的任意 2 张, 有 $= \frac{13C_2}{52C_2}$, 注意 $nCk = \frac{n!}{k!(n-k)!}$

例: 一批产品共有 100 件, 其中 5 件次品, 从中任取 50 件问无次品的概率多少

解: 基本事件 100 抽 50 个, 事件 95 个非次品里抽 50 个, $P(B) = \frac{95C_{50}}{100C_{50}}$

例: 一批产品共有 100 件, 其中 5 件次品, 从中任取 50 件问刚好有 2 件次品的概率多少

解: 基本事件 100 抽 50 个, 事件 95 个非次品里抽 48 个 $\times$ 5 个次品里抽 2 个, $P(B) = \frac{95C_{48} \times 5C_2}{100C_{50}}$

超几何模型的通用形式: N 件产品里 M 个次品, 取 n 件恰好有 m 个次品概率: $P(B) = \frac{N-M}{N} \frac{C_{n-m} \times M}{C_n} \frac{C_m}{C_n}$

多分类古典概型: N 件产品里分 k 类产品, 第 i 类有 N_i 个产品, 取 n 件恰好有 m_i 个产品属于第 i 类的概率: $P(B) = \frac{N_1 C_{m_1} \times \dots \times N_k C_{m_k}}{N C_n}$

若事件 A 发生必然导致事件 B 发生, 则称 B 包含 A, 记作 $A \subset B$ 或 $B \supset A$

相等: 若 $A \subset B$ 且 $B \subset A$, 则 $A = B$

事件的基本运算: 并 (和事件): $A \cup B$ (或 $A + B$), 表示 A 或 B 发生 (至少有一个发生)

交 (积事件): $A \cap B$ (或 AB), 表示 A 且 B 发生 (两个都发生)

对立事件: $\bar{A}$, 表示“非 A”

差事件: $A \setminus B$, 表示 A 发生而 B 不发生。恒有 $A \setminus B = A\bar{B}$

运算规律: 分配律: $A(B \cup C) = AB \cup AC$; $A \cup (BC) = (A \cup B)(A \cup C)$

德·摩根律 (对偶律): $\overline{A \cup B} = \bar{A} \cap \bar{B}$; $\overline{A \cap B} = \bar{A} \cup \bar{B}$

互不相容性: 若 $A \cap B = \emptyset$ (不可能事件), 则称 A 与 B 互不相容

概率加法公式: 若 A, B 互不相容: $P(A \cup B) = P(A) + P(B)$

任意两个事件的加法公式: $P(A \cup B) = P(A) + P(B) - P(AB)$

证明: 因为 $A \cup B = A \cup (B\bar{A})$ 且 $A \cap (B\bar{A}) = \emptyset$, 所以 $P(A \cup B) = P(A) + P(B\bar{A})$

又因为 $B = BA \cup B\bar{A}$ 且两部分互不相容, 有 $P(B) = P(BA) + P(B\bar{A}) \Rightarrow P(B\bar{A}) = P(B) - P(AB)$, 代入前式即证

常用公式: $P(\bar{A}) = 1 - P(A)$; $P(B\bar{A}) = P(B) - P(AB)$

完全可加性: 若一系列事件 $A_1, A_2, \dots$ 两两互不相容, 则: $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$

例: 袋中有红、黄、白球各一个。每次任取一个, 有放回地抽取 3 次。问取到的三球里没有红球或者没有黄球的概率?

解: 记 A = 没有红球, B = 没有黄球。题目求 $P(A \cup B)$ 。

每次试验无红球概率为 $2/3$, 三次独立抽取, 故 $P(A) = (2/3)^3 = 8/27$ 。

同理, 无黄球概率 $P(B) = (2/3)^3 = 8/27$ 。

AB = 既没有红球也没有黄球 = 三次全部抽到白球。故 $P(AB) = (1/3)^3 = 1/27$

加法公式: $P(A \cup B) = P(A) + P(B) - P(AB) = \frac{8}{27} + \frac{8}{27} - \frac{1}{27} = \frac{15}{27} = \frac{5}{9}$

条件概率、乘法公式、独立性条件概率：

条件概率：在事件 A 发生的前提下，事件 B 发生的概率，定义为：

$$P(B|A) = \frac{P(AB)}{P(A)} \quad (P(A) \neq 0)$$

乘法公式： $P(AB) = P(A)P(B|A) = P(B)P(A|B)$

相互独立性：定义：若 $P(B|A) = P(B)$ ，即 A 的发生不影响 B 发生的概率，称 A 与 B 相互独立。其等价的定义式为： $P(AB) = P(A)P(B)$

对立事件独立性定理：若四对事件 $(A, B; \bar{A}, B; A, \bar{B}; \bar{A}, \bar{B})$ 中有一对相互独立，则其余三对也相互独立。证明（以 A, B 独立推 $A, \bar{B}$ 独立为例）：因为 $A = A\bar{B} \cup AB$ ，且两部分互不相容，故 $P(A) = P(A\bar{B}) + P(AB)$ 。由此可得 $P(A\bar{B}) = P(A) - P(AB)$ 。因 A, B 独立，代入 $P(AB) = P(A)P(B)$ ，得： $P(A\bar{B}) = P(A) - P(A)P(B) = P(A)[1 - P(B)] = P(A)P(\bar{B})$ 。证毕。

多个事件的相互独立：称 $A_1, A_2, \dots, A_n$ 相互独立，是指对于其中任意 k 个事件 $(1 < k \leq n)$ 的交事件，其概率都等于各自概率的乘积。核心注意点：两两独立 $\neq$ 相互独立

例：某人投篮命中率为 70%，投了 2 次（相互独立），问至少一次命中的概率

解（加法公式）：记 A, B 为第一、二次命中。

$$P(A \cup B) = P(A) + P(B) - P(AB) = 0.7 + 0.7 - (0.7 \times 0.7) = 1.4 - 0.49 = 0.91$$

解（对立事件）： $P(\text{至少一次}) = 1 - P(\bar{A} \cap \bar{B}) = 1 - P(\bar{A})P(\bar{B}) = 1 - 0.3 \times 0.3 = 0.91$

例（两两独立 $\neq$ 相互独立的反例）：正四面体四个面分别染上：红、黄、蓝、三色（红黄蓝共存）。随机掷出，设 A = 出现红色， B = 出现黄色， C = 出现蓝色。证明它们两两独立，但不相互独立

解：每面朝上概率为 $1/4$ ， $P(A)=1/4+1/4=1/2$ ， $P(B)=1/4+1/4=1/2$ ，同时包含红黄的只有三色面， $P(AB)=1/4$ ，因为 $P(A)P(B)=P(AB)$ 所以 AB 独立，同理 BC, AC 也两两独立，但三个事件不相互独立，因为 $P(ABC)=1/4$ 而 $P(A)P(B)P(C)=1/8$

全概率公式：设事件组 $A_1, A_2, \dots, A_n$ 互不相容且构成完备事件组 $(\bigcup A_i = \Omega)$ ，且 $P(A_i) > 0$ 。则对任意事件 B ，有：

$$P(B) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

证明：由于 Ω 被分割，事件 $B = B \cap \Omega = \bigcup_{i=1}^n (BA_i)$ 。因为 BA_i 互不相容，根据可加性及条件概率乘法公式展开： $P(B) = \sum P(BA_i) = \sum P(B|A_i)P(A_i)$ 。

贝叶斯公式（逆概公式）：用于在已知结果 B 发生的条件下，推测是由原因 A_j 导致的概率：

$$P(A_j|B) = \frac{P(B|A_j)P(A_j)}{\sum_{i=1}^n P(B|A_i)P(A_i)}$$

例（飞机坠毁问题）：三人向同一飞机射击，命中率分别为 0.4, 0.5, 0.7。若只有 1 人射中，坠毁概率为 0.2；2 人射中，坠毁概率 0.6；3 人射中，飞机必坠毁，求飞机坠毁的概率

解：记 A_k = 恰有 k 人击中 ($k = 0, 1, 2, 3$), B = 飞机坠毁。算各射中人数的边缘概率：

$$P(A_0) = 0.6 \times 0.5 \times 0.3 = 0.09$$

$$P(A_1) = (0.4 \times 0.5 \times 0.3) + (0.6 \times 0.5 \times 0.3) + (0.6 \times 0.5 \times 0.7) = 0.36$$

$$P(A_2) = (0.4 \times 0.5 \times 0.3) + (0.4 \times 0.7 \times 0.5) + (0.6 \times 0.5 \times 0.7) = 0.41$$

$$P(A_3) = 0.4 \times 0.5 \times 0.7 = 0.14$$

题目给的条件概率为： $P(B|A_0) = 0, P(B|A_1) = 0.2, P(B|A_2) = 0.6, P(B|A_3) = 1$ 。

由全概公式： $P(B) = (0 \times 0.09) + (0.2 \times 0.36) + (0.6 \times 0.41) + (1 \times 0.14) = 0.458$ 。

例（艾滋病检测/贝叶斯）：某人群中艾滋病感染率 $P(A) = 0.001$ 。检测灵敏度满足：假阴性（测出阴实际阳）概率为 0.05（即 $P(\bar{T}|A) = 0.05 \Rightarrow P(T|A) = 0.95$ ），假阳性（测出阳实际阴）概率为 0.01（即 $P(T|\bar{A}) = 0.01$ ）。现一人检测结果呈阳性（ T ），求他真患病的概率 $P(A|T)$

解：由贝叶斯公式

$$P(A|T) = \frac{P(T|A)P(A)}{P(T|A)P(A) + P(T|\bar{A})P(\bar{A})} = \frac{0.95 \times 0.001}{0.95 \times 0.001 + 0.01 \times 0.999} \approx 0.0868 \quad (8.68\%)$$

独立试验序列概型（伯努利概型）

伯努利定理：设单次试验中事件 A 发生的概率为 p ($0 < p < 1$)。则在 n 次重复独立试验中，事件 A 恰好发生 k 次的概率为：

$$P(A \text{ 发生 } k \text{ 次}) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, 2, \dots, n$$

证明：单次试验结果用序列 $(x_1, \dots, x_n)$ 表示，发生记 1，不发生记 0。由于独立性，某一特定发生 k 次的序列概率为 $p^k q^{n-k}$ （其中 $q = 1-p$ ）。而在 n 次试验中，这类互不相容的序列组合共 $\binom{n}{k}$ 个，相加即证
例射击打中目标的概率为 0.001，射击 5000 次，求至少两次打中的概率。解答：利用对立事件简化计算
 $P(\text{至少 } 2 \text{ 次}) = 1 - P(0 \text{ 次}) - P(1 \text{ 次}) = 1 - \binom{5000}{0} (0.001)^0 (0.999)^{5000} - \binom{5000}{1} (0.001)^1 (0.999)^{4999} \approx 0.9596$

随机变量与概率分布

随机变量的基本概念定义：对于概率空间 $(\Omega, \mathcal{F}, P)$ ，若对样本空间中的每一个可能结果 ω ，都唯一对应一个实数值 $X(\omega)$ ，则称 X 为随机变量。严格的数学定义要求对任意实数 r ，均有 $\{\omega : X(\omega) \leq r\} \in \mathcal{F}$
分类：离散型随机变量（取值有限或可数）与连续型随机变量（取值充满区间）

离散随机变量的性质为： $p_k = P(X = x_k) \geq 0$ 且 $\sum_k p_k = 1$

主要的离散分布：

二点分布（伯努利分布）分布律： $P(X = 1) = p, P(X = 0) = 1 - p$

二项分布 $B(n, p)$ 分布律： $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$

二项分布可以看作是 n 个独立的二点分布随机变量之和

几何分布分布律： $P(X = k) = p(1-p)^{k-1}, \quad k = 1, 2, \dots$ （不成功不罢休，第 k 次才成功）

负二项分布分布律： $P(X = n) = \binom{n-1}{k-1} p^k (1-p)^{n-k}, \quad n = k, k+1, \dots$ （直到成功 k 次才罢休）

超几何分布分布律： $P(X = m) = \frac{\binom{M}{m} \binom{N-M}{n-m}}{\binom{N}{n}}$ （不放回抽样模型）

当 $N \rightarrow \infty$ 且 $\frac{M}{N} \rightarrow p$ 时，无放回抽样的超几何收敛于有放回抽样的二项： $\frac{\binom{M}{m} \binom{N-M}{n-m}}{\binom{N}{n}} \rightarrow \binom{n}{m} p^m (1-p)^{n-m}$

泊松分布 $P(\lambda)$ 分布律： $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots$

泊松分布适用情景：对单位时间内发生的数数 (Count) 事件建模 (如放射性粒子数、高速出口车流量等)

泊松定理 (二项分布的极限)：将总时间分成 n 个极小区间，若 $n \rightarrow \infty$ 且 $np_n = \lambda$ ，则伯努利分布极限形式为泊松分布： $\binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow \frac{\lambda^k}{k!} e^{-\lambda}$

连续型随机变量概率密度函数 $p(x)$ 的定义：若存在非负可积函数 $p(x)$ ，使得对任意 $a < b$ ，则有：

$$P(a < X < b) = \int_a^b p(x) dx$$

基本性质：任意单点的概率为零： $P(X = a) = 0$ 。 $\int_{-\infty}^{\infty} p(x) dx = 1$

在 $p(x)$ 的连续点处，有分布函数的高阶关系： $F'(x) = p(x)$

均匀分布 $U[a, b]$ ： $p(x) = \frac{1}{b-a} I_{a \leq x \leq b}$ ，区间内落入某子区间的概率与区间长度成正比

指数分布 $Exp(\lambda)$ ： $p(x) = \lambda e^{-\lambda x} I_{x \geq 0}$ ，具有无记忆性，常用于物品寿命建模

正态分布 $N(\mu, \sigma^2)$ ： $p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ ，关于 $x = \mu$ 对称，钟形曲线， σ 决定宽度

Γ 分布： $p(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} I_{x > 0}$ ；注意 $\Gamma(1, \beta)$ 即指数分布； $\Gamma(\frac{n}{2}, \frac{1}{2})$ 为 $\chi^2(n)$ 分布

韦布尔 (Weibull) 分布： $f(x) = \frac{k}{\lambda} \left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k} I_{x \geq 0}$ ，可靠性研究产品寿命； $k = 1$ 时退化为指数分布

分布函数与随机变量函数的分布

分布函数 (cdf) 的定义： $F(x) = P(X \leq x)$, $x \in \mathbb{R}$

性质： $0 \leq F(x) \leq 1$ ；单调不减；右连续； $F(-\infty) = 0, F(+\infty) = 1$

这三个概念示例比如令 X 表示骰子掷出的点数，可取 123456，对应概率 $f(1) = f(2) = f(3) = f(4) = f(5) = f(6) = \frac{1}{6}$ ，累积分布 $F(x) = P(X \leq x)$ ，比如 $2 \leq x < 3$ 对应 $F(x) = f(1) + f(2) = \frac{1}{3}$

如果 $x \geq 6$ 则对应 $F(x) = 1$ ；注意具体值 $P(X \leq 3) = F(3) = 3/6 = 0.5$ ； $P(X = 3) = f(3) = 1/6$ ； $F(3) - F(3^-) = 3/6 - 2/6 = 1/6$

随机变量一维变换 $Y = f(X)$ 的密度求解步骤，分布函数法 (第一准则) 或者公式法：

一：先列出 $F_Y(y) = P(f(X) \leq y)$ ，将其转化为用 X 的区间表示，最后对 y 求导： $p_Y(y) = F'_Y(y)$

二：若 $f(x)$ 严格单调，导数连续且处处不为 0，其反函数为 $x = g(y)$ ，则：

$$p_Y(y) = p_X(g(y)) \cdot |g'(y)| \cdot I_{A \leq y \leq B}$$

概率变换定理 (重要)：若 X 的分布函数为 $F(x)$ 且连续，则新变量 $Y = F(X) \sim U[0, 1]$ (用于生成均匀随机数)。反之，若 $U \sim U[0, 1]$ ，则 $X = F^{-1}(U)$ 的分布函数即为 $F(x)$ (逆变换采样法)

例 (求电子管寿命分布律)：电子管已工作 t 小时，在随后 Δt 内损坏的条件概率为 $\lambda \Delta t + o(\Delta t)$ ，求寿命 X 的分布

解：题目已给电子管在 $t + \Delta t$ 时刻内损坏的条件概率，条件是电管已经工作 t 小时，

$$\frac{P(t < X < t + \Delta t)}{P(X > t)} = \lambda \Delta t + o(\Delta t) \Rightarrow \frac{F(t + \Delta t) - F(t)}{1 - F(t)} = \lambda \Delta t + o(\Delta t)$$

两边同除以 Δt 并在 $\Delta t \rightarrow 0$ 取极限得微分方程：

$$\frac{F'(t)}{1 - F(t)} = \lambda \Rightarrow -\frac{d}{dt} \ln(1 - F(t)) = \lambda \Rightarrow \ln(1 - F(t)) = -\lambda t + C_0$$

结合初始条件 $F(0) = 0 \Rightarrow C_0 = 0$ ，最终求得 $F(t) = 1 - e^{-\lambda t}$ ($t > 0$)。对 t 求导得 $p(t) = \lambda e^{-\lambda t} I_{t > 0}$ 即电子管寿命服从指数分布

例 (连续型一维变量求导变换): 已知 $X \sim N(\mu, \sigma^2)$, 求 $Y = \frac{X-\mu}{\sigma}$ 的密度函数

解: 有以下公式

$$F_Y(y) = P\left(\frac{X-\mu}{\sigma} \leq y\right) = P(X \leq \sigma y + \mu) = F_X(\sigma y + \mu)$$

$F_Y(y) = F_X(\sigma y + \mu)$ 两边同时对 y 求导:

$$p_Y(y) = \sigma \cdot p_X(\sigma y + \mu) = \sigma \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\sigma y + \mu - \mu)^2}{2\sigma^2}} = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$$

因此 $Y \sim N(0, 1)$ (标准正态分布)

例 (非单调变换-平方变换): 设 $f_X(x) = x^3 e^{-x^2} I_{x \geq 0}$, 求 $Y = X^2$ 的概率密度

解: 因为 $X \geq 0$, 所以 $Y \geq 0$.

$$F_Y(y) = P(X^2 \leq y) = P(X \leq \sqrt{y}) = F_X(\sqrt{y}) \quad (y \geq 0)$$

$F_Y(y) = F_X(\sqrt{y})$ 两边同时对 y 求导得:

$$f_Y(y) = \frac{1}{2\sqrt{y}} \cdot f_X(\sqrt{y}) = \frac{1}{2\sqrt{y}} \cdot (\sqrt{y})^3 e^{-(\sqrt{y})^2} I_{y \geq 0} = \frac{y e^{-y}}{2} I_{y \geq 0}$$

随机变量的数字特征

算术期望 (均值) 定义: 期望是随机变量随取值概率加权的平均数

离散型: $E(X) = \sum_k x_k p_k$ (级数必须绝对收敛, 即 $\sum |x_k| p_k < \infty$, 否则期望不存在)

连续型: $E(X) = \int_{-\infty}^{\infty} x p(x) dx$ (要求 $\int |x| p(x) dx < \infty$)

核心分布的期望公式: (做正态近似的时候代入到 μ 里: $\frac{X-\mu}{\sigma}$)

均匀分布 $E(X) = \frac{a+b}{2}$; 二点分布 $E(X) = p$; 二项分布 $E(X) = np$

泊松分布 $E(X) = \lambda$; 注意独立事件可加性 $X \sim P(\lambda_1), Y \sim P(\lambda_2), X + Y \sim P(\lambda_1 + \lambda_2)$

Γ 分布 $E(X) = \frac{\alpha}{\beta}$; 超几何分布 $E(X) = \frac{nM}{N}$

指数分布 $E(X) = \frac{1}{\lambda}$; 正态分布 $E(X) = \mu$

期望的简单性质及函数期望公式

线性性质: $E(kX + b) = kE(X) + b$ (对常数 k, b 恒成立), $E(X + Y) = E(X) + E(Y)$

如果 X, Y 独立, 则有 $E(XY) = E(X)E(Y)$

一元随机变量函数期望公式 (省去求 Y 分布的步骤)

离散型: $E[f(X)] = \sum_i f(x_i) p_i$

连续型: $E[f(X)] = \int_{-\infty}^{\infty} f(x) p(x) dx$

方差及其性质

定义: 方差度量了随机变量与其中心 (期望) 的偏离分散程度: $D(X) = E([X - E(X)]^2)$

计算核心公式: $D(X) = E(X^2) - [E(X)]^2$

$D(X + Y) = D(X) + D(Y) + 2Cov(X, Y)$, 其中 $Cov(X, Y) = E((X - E(X))(Y - E(Y))) = E(XY) - E(X)E(Y)$

如果 X, Y 独立, 则有 $E(XY) = E(X)E(Y)$ 且 $Cov(X, Y) = 0$, 因此 $D(X + Y) = D(X) + D(Y)$

注意理论（总体）皮尔逊相关系数 $\rho_{XY} = \frac{Cov(X,Y)}{\sqrt{D(X)D(Y)}}$ ，基于随机变量的总体协方差和方差的定义

同样有经验（样本）皮尔逊相关 $r_{XY} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{S_{XY}}{S_{XX}S_{YY}}$ ，基于样本数据的计算公式

重要方差线性性质：对任意常数 k, b ，有 $D(kX + b) = k^2 D(X)$ （常数平移不改变分散度）

核心分布方差：

均匀分布： $D(X) = \frac{(b-a)^2}{12}$ ；二点分布： $D(X) = p(1-p)$ ；二项分布： $D(X) = np(1-p)$

泊松分布： $D(X) = \lambda$ ；指数分布： $D(X) = \frac{1}{\lambda^2}$ ；正态分布： $D(X) = \sigma^2$

切比雪夫不等式：若随机变量具有期望 $E(X)$ 与方差 $D(X)$ ，则对任意 $\epsilon > 0$ ： $P(|X - E(X)| \geq \epsilon) \leq \frac{D(X)}{\epsilon^2}$ ；

若设 $\epsilon = k\sqrt{D(X)}$ ，则该公式表现为 $P(|X - E(X)| \geq k\sigma) \leq \frac{1}{k^2}$

矩与分位数

原点矩与中心矩： $E(X^k)$ 称为 X 的 k 阶原点矩

$E[(X - E(X))^k]$ 称为 X 的 k 阶中心矩（方差即 2 阶中心矩）

分位数定义：若连续变量满足 $F(x_p) = p$ ，则 x_p 称为 p 分位数

当 $p = 1/2$ 时，该位置点特称为中位数

随机向量

随机向量的联合分布与边缘分布

将多个随机变量组合为一个整体 $\vec{\zeta} = (X, Y)$ 进行研究，称为二维随机向量

二维离散型随机向量联合分布律：

$P(X = x_i, Y = y_j) = p_{ij}$ ，满足 $\sum_i \sum_j p_{ij} = 1$

边缘分布律计算（行/列求和法）： $P(X = x_i) = \sum_j p_{ij}$ ， $P(Y = y_j) = \sum_i p_{ij}$

二维连续型随机向量联合密度函数 $p(x, y)$ ：

落入任意平面矩形（或可测区域 D ）的概率为： $P((X, Y) \in D) = \iint_D p(x, y) dx dy$

边缘密度函数计算（积掉另一个变量）： $p_X(x) = \int_{-\infty}^{\infty} p(x, y) dy$ ， $p_Y(y) = \int_{-\infty}^{\infty} p(x, y) dx$

随机变量的独立性定义：若对任意开区间均满足联合概率等于各自概率之积，则 X, Y 独立

连续型判定条件：联合密度等于边缘密度相乘： $p(x, y) = p_X(x)p_Y(y)$

离散型判定条件：联合分布律等于边缘分布律相乘： $P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$

例（二维均匀分布综合应用）：设 (X, Y) 充分布在由曲线 $y = x$ 与 $y = x^2$ 所包围的平面区域 G 上的均匀分布，求联合密度及各自的边缘密度

解：求区域面积与联合密度常数 a ：两曲线交点为 $(0, 0)$ 与 $(1, 1)$ ，

$$S = \iint_G dx dy = \int_0^1 \left(\int_{x^2}^x dy \right) dx = \int_0^1 (x - x^2) dx = \left[\frac{x^2}{2} - \frac{x^3}{3} \right]_0^1 = \frac{1}{6}$$

因为是均匀分布，联合密度为其面积的倒数： $p(x, y) = \frac{1}{S} I_G(x, y) = 6 I_G(x, y)$

求 X 的边缘密度（注意：对给定 x ， y 的取值从 x^2 到 x ）： $p_X(x) = \int_{x^2}^x 6 dy = 6(x - x^2)$ ， $0 \leq x \leq 1$ ；

求 Y 的边缘密度（注意：对给定 y ， x 的下限从直线得到 $x = y$ ，上限从抛物线得到 $x = \sqrt{y}$ ）： $p_Y(y) = \int_y^{\sqrt{y}} 6 dx = 6(\sqrt{y} - y)$ ， $0 \leq y \leq 1$

假设检验

先建立一个原假设 H_0 (通常是数据的某种分布或参数认识); 如果原假设成立, 那么观察到某特定极端样本事件的概率应该非常小 (例如 ≤ 0.05); 如果在这个单次试验中该小概率事件居然发生了, 我们就有理由怀疑原假设的正确性, 从而拒绝原假设

P-value: 原假设 H_0 实际上正确的情况下, 观测到当前统计量或更极端值的概率, 值越小证据越强
第一类错误 (Type I Err, α): 当原假设 H_0 实际上正确, 但我们由于样本极端而拒绝了它; 弃真错误

1. 构造统计量: 构造一个合适的统计量, 要求它在原假设 H_0 成立的条件下, 其分布是已知的 (例如服从标准正态分布、 t 分布或 χ^2 分布)
2. 确定拒绝域 (Rejection Region, W) 的形式: 思考在什么样本观测值下倾向于推翻 H_0 (通常是统计量绝对值过大, 偏离核心区域)
3. 控制第一类错误概率 α 以确定临界值 (Critical Value)

单个正态总体的假设检验 (对单个正态总体 $X \sim N(\mu, \sigma^2)$, 根据已知或未知的参数, 有三类流程)

- (1) 方差 σ^2 已知, **检验均值** $H_0: \mu = \mu_0$ (Z 检验)

统计量: $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$

拒绝域: $W = \{|Z| \geq z_{1-\alpha/2}\}$ (双侧检验), 总体均值的置信区间 $\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$

决策: 当观测到的样本均值计算出的 $|Z|$ 落在拒绝域内时, 拒绝 H_0

- (2) 方差 σ^2 未知, **检验均值** $H_0: \mu = \mu_0$ (单样本 t 检验)

统计量: $t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ (其中 S 为样本标准差)

拒绝域: $W = \{|t| \geq t_{1-\alpha/2}(n-1)\}$, 总体均值的置信区间 $\bar{X} \pm t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}$

决策: 若样本计算出的 $|t| \geq$ 临界值, 则拒绝 H_0

- (3) **检验总体方差** $H_0: \sigma = \sigma_0$ (卡方 χ^2 检验)

统计量: $\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$

拒绝域: 由两侧小概率尾部组成, 即 $\chi^2 > \lambda_1$ 或 $\chi^2 < \lambda_2$, 总体方差的置信区间 $(\frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}, \frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2})$

确定临界值: $P(\chi^2 > \lambda_1) = \frac{\alpha}{2} \implies \lambda_1 = \chi_{1-\alpha/2}^2(n-1)$ $P(\chi^2 < \lambda_2) = \frac{\alpha}{2} \implies \lambda_2 = \chi_{\alpha/2}^2(n-1)$

控制两侧尾部概率均为 $\frac{\alpha}{2}$

两个正态总体的假设检验

- (1) **两个总体方差的比较** $H_0: \sigma_1^2 = \sigma_2^2$ (F 检验)

统计量: $F = \frac{S_1^2}{S_2^2} \sim F(n_1-1, n_2-1)$

拒绝域与临界值: 控制第一类错误 α , 拒绝域为 $F > \lambda_1$ 或 $F < \lambda_2$

$\lambda_1 = F_{1-\alpha/2}(n_1-1, n_2-1)$

$\lambda_2 = F_{\alpha/2}(n_1-1, n_2-1)$

- (2) 方差未知但相等 ($\sigma_1^2 = \sigma_2^2 = \sigma^2$), **检验两总体均值差** $H_0: \mu_1 = \mu_2$ (两独立样本 t 检验)

由于 σ^2 未知, 需要通过两组样本的数据进行联合估计 (Pooled Estimation)

联合方差估计: $S_p^2 = \frac{\sum_{i=1}^{n_1} (X_i - \bar{X})^2 + \sum_{j=1}^{n_2} (Y_j - \bar{Y})^2}{n_1 + n_2 - 2}$

统计量: $t = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$

决策: 若计算得到的绝对值 $|t| > t_{1-\alpha/2}(n_1 + n_2 - 2)$, 则拒绝原假设, 认为两组均值有显著差异

样本含量与检验效能 (Power) 计算

第二类错误 (Type II Error, β): 当原假设 H_0 实际上是错误的, 但由于样本分布原因, 未能拒绝 H_0

检验效能 (Power, $1 - \beta$): 当原假设 H_0 错误时, 能正确拒绝 H_0 并检出真实差异的概率

例: 假设在临床试验中决定在治疗组和对照组中各招募 100 名患者 (即 $n_{trmt} = n_{ctrl} = 100$)。已知新药相比标准药物能额外降血压 3 mmHg (即真实的效应差值 $\mu_{trmt} - \mu_{ctrl} = -3$ mmHg)。假设两组差值的 Null Distribution 标准差为 1.7! 注意了合并方差如果不给要这样算: $sd(\bar{X} - \bar{Y}) = \sqrt{\frac{12^2}{100} + \frac{12^2}{100}} = 1.7$

问: 能够成功检测出该血压下降 (即拒绝原假设) 的概率 (检验效能 Power) 是多少?

问: 要想达到更高的 Power (比如 80% 或 90%), 应该如何估算所需的样本含量?

解: 明确零分布 (Null Distribution) 与拒绝域。在原假设 $H_0: \mu_{trmt} - \mu_{ctrl} = 0$ 下, 两样本均值之差服从均值为 0, 标准差为 1.7 的分布: 两组的 $X_1, X_2, \dots \sim N(\mu, 12^2)$; $\bar{X}_{trmt} - \bar{X}_{ctrl} \sim N(0, 1.7^2)$, $\frac{\bar{X}_{trmt} - \bar{X}_{ctrl}}{\sqrt{\frac{12^2}{n} + \frac{12^2}{n}}} \sim N(0, 1)$ 。如果选择进行双侧检验 ($\alpha = 0.05$), 对应的双侧临界 Z 值为 ± 1.96 。因此, 左侧拒绝域的边界 (以实际血压差值表示) 为: 临界值 $= 0 - 1.96 \times 1.7 = -3.332$ mmHg。也就是说, 只有当实验观测到新药比对照组多降低 3.332 mmHg 以上时, 才能拒绝 H_0

解: 计算在真实疗效下的 Power。然而, 新药的真实疗效是额外降低 3 mmHg (这意味着真实的备择分布以 -3 为中心, 而不是以 0 为中心) 真实的抽样分布为: $\bar{X}_{trmt} - \bar{X}_{ctrl} \sim N(-3, 1.7^2)$ 。要计算真实分布落在拒绝域 (< -3.332) 内的比例: 根据标准正态变换, 计算真实分布下的 Z 分数: $Z = \frac{\text{临界值} - \text{真实均值}}{\text{标准差}} = \frac{-3.332 - (-3)}{1.7} = \frac{-0.332}{1.7} \approx -0.20$ 。通过查标准正态分布表 (或统计软件) 计算单侧尾部面积: $\text{Power} = P(Z < -0.20) \approx 0.4207 = 42\%$ 。结论: 如果两组各用 100 个样本, 只有 42% 的把握能成功检测出这个有临床意义的 3 mmHg 降压差异。说明 100 的样本含量远不够 (易犯二类错误)

样本含量 (Sample Size) 的逆向推导: 若希望达到 80% 的检验功效 (Power = 0.80), 每组需要多少样本含量? 由公式可知, 两独立样本均值比较的每组样本量计算公式为:

$$n = \frac{2\sigma^2(z_{1-\alpha/2} + z_{1-\beta})^2}{\delta^2}$$

其中: σ 是单个总体的标准差, δ 是拟检出的临床最小显著差值 (本题中为 3 mmHg), $z_{1-\alpha/2} = 1.96$ (当 $\alpha = 0.05$ 时)。 $z_{1-\beta} = 0.84$ (当 Power = 0.80, $\beta = 0.20$ 时)。将参数代入该经典数理统计公式中, 即可精确求出各组所对应的必要样本例数 n , 这也是进行临床或生物学实验设计前最关键的统计学步骤

线性回归与多元线性回归

简单线性回归 (Simple Linear Regression)

研究两个连续变量 X 与 Y 之间的线性关系, 建立简单线性回归模型: $Y = \beta_0 + \beta_1 X + \epsilon$ (正向回归)

β_0 : 截距 (Intercept); β_1 : 斜率, 即 X 每变动一个单位时, Y 的平均变动量; ϵ : 随机误差项

正向 $\beta_1 = r \frac{\sigma_Y}{\sigma_X}$, 反向回归 $X = \beta'_0 + \beta'_1 Y + \epsilon$, 其中 $\beta'_1 = r \frac{\sigma_X}{\sigma_Y}$, 所以 $\beta'_1 = \frac{r^2}{\beta_1}$

高斯-马尔可夫假设, 为了保证参数估计的优良性质, 模型对误差项 ϵ 有严格的假定 (LINE)

线性 (Linearity): X 和 Y 具有线性结构关系: $E(Y|X) = \beta_0 + \beta_1 X$ (条件均值是 X 的线性函数)

独立性 (Independence): 任意两个样本的误差项 ϵ_i 和 ϵ_j 相互独立;

期望为 0 (Expectation): $E(\epsilon_i) = 0$, 不同观测值之间的误差相互独立且 $\epsilon \sim N(0, \sigma^2)$ (常用于统计推断);

方差齐性 (Homoscedasticity): 所有的误差项具有相同的方差, 即 $D(\epsilon_i) = \text{Var}(Y|X) = \text{Var}(\epsilon) = \sigma^2$;

正态性 (Normality): $\epsilon_i \sim N(0, \sigma^2)$ (在进行 t 检验和置信区间估计时必须满足)

最小二乘估计 (Ordinary Least Squares, OLS)

核心思想：寻找估计值 $\hat{\beta}_0$ 和 $\hat{\beta}_1$ ，使得观测值 Y_i 与拟合值 $\hat{Y}_i$ 之间的残差平方和 (RSS) 达到最小：

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2 \rightarrow \min$$

求导推导（解正规方程组）：对 β_0 和 β_1 分别求偏导并令其等于 0：

$$\frac{\partial Q}{\partial \beta_0} = -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i) = 0$$

$$\frac{\partial Q}{\partial \beta_1} = -2 \sum_{i=1}^n X_i (Y_i - \beta_0 - \beta_1 X_i) = 0$$

最终估计公式：

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{l_{XY}}{l_{XX}}, \quad \text{置信区间 } \hat{\beta}_1 \pm t_{\alpha/2, n-2} \cdot Se(\hat{\beta}_1)$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

预测值： $\hat{y}_i = \beta_0 + \beta_1 x_i$

注意当 X 固定的时候 Y 的随机性都来自于 ϵ ， $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$ ，单个误差项 $\epsilon_i \sim i.i.d N(0, \sigma^2)$

误差的方差估计： $\hat{\sigma}^2 = \frac{RSS}{n-2}$ （自由度为 $n-2$ ，反映数据点围绕回归直线的平均波动大小）

残差平方和 $RSS = \sum_{i=1}^n (y_i - \hat{y})^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i - \epsilon_i)^2$ ，被用于计算系数的标准误

平方和标记

离均平方和： $S_{XX} = \sum (x_i - \bar{x})^2$ ； $S_{YY} = \sum (y_i - \bar{y})^2$ $S_{XY} = \sum (x_i - \bar{x})(y_i - \bar{y})$

残差平方和： $SS_{\text{残差}} = RSS = \sum_i^n (y_i - \hat{y}_i)^2$

回归平方和：衡量的是模型预测值相对于总均值的变异 $SS_{\text{回归}} = \sum_i^n (\hat{y}_i - \bar{y})^2$

等式：总平方和 $SS_{\text{总}} = SS_{\text{残差}} + SS_{\text{回归}}$ ；相当于 $\sum (y_i - \bar{y})^2 = \sum (y_i - \hat{y}_i)^2 + \sum (\hat{y}_i - \bar{y})^2$

参数估计：最小二乘，找到一条直线使得所有数据点到该直线的垂直距离的平方和最小

参数解： $\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$ ， $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

参数的统计推断：若误差正态，则 $\hat{\beta}_0, \hat{\beta}_1$ 服从正态分布

检验 $\beta_1 = 0$ 与否，检验统计量 $\frac{\hat{\beta}_1 - \beta_1(H_0 \text{ 设为 } =0)}{Se(\hat{\beta}_j)} \sim t(n-2)$

多元线性回归的话检验某个自变量 X_j 是否对因变量 Y 有显著的线性影响，是否 $\beta_j = 0$

检验统计量（误差独立、同方差、正态假设下）： $\frac{\hat{\beta}_j - \beta_j}{Se(\hat{\beta}_j)} \sim t(n-p-1)$ ，单变量的 df 就是 $n-2$

$Se(\hat{\beta}_j)$ 即 $\hat{\beta}_j$ 的标准误， $Se(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2}{S_{XX}}} = \sqrt{\frac{\hat{\sigma}^2}{\sum (X_i - \bar{X})^2}}$ ， $\hat{\sigma} = \sqrt{\frac{RSS}{n-p-1}} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n-p-1}}$

另有 $\hat{\beta}_0$ 的标准误 $Se(\hat{\beta}_0) = \hat{\sigma} \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{XX}}}$

模型评估和推断：

决定系数 R^2 ：衡量模型的拟合优度（表示 X 能解释 Y 的变异比例）

$$R^2 = \frac{SS_{\text{回归}}}{SS_{\text{总}}} = 1 - \frac{SS_{\text{残差}}}{SS_{\text{总}}} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} = 1 - \frac{SS_{\text{残差}}}{SS_{\text{总}}}$$

多元线性回归 (Multiple Linear Regression)

矩阵形式设定：当自变量有多个 (p 个) 时，模型扩展为多元线性回归：

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \epsilon_i$$

写成矩阵形式：

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

其中 $\mathbf{Y}$ 是 $n \times 1$ 的因变量向量， $\mathbf{X}$ 是 $n \times (p+1)$ 的设计矩阵 (第一列全为 1, 对应截距项), $\boldsymbol{\beta}$ 是 $(p+1) \times 1$ 的回归系数向量, $\boldsymbol{\epsilon}$ 是 $n \times 1$ 的误差向量

矩阵形式下的 OLS 估计残差平方和可以写成向量内积的形式：

$$Q(\boldsymbol{\beta}) = \boldsymbol{\epsilon}^T \boldsymbol{\epsilon} = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \mathbf{Y}^T \mathbf{Y} - 2\boldsymbol{\beta}^T \mathbf{X}^T \mathbf{Y} + \boldsymbol{\beta}^T \mathbf{X}^T \mathbf{X} \boldsymbol{\beta}$$

对向量 $\boldsymbol{\beta}$ 求导并令其为 0：

$$\frac{\partial Q}{\partial \boldsymbol{\beta}} = -2\mathbf{X}^T \mathbf{Y} + 2\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = 0 \implies \mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{Y}$$

只要 $\mathbf{X}^T \mathbf{X}$ 可逆 (即不存在完全多重共线性)，就能解得极具考点的多元 OLS 估计公式：

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

回归模型的显著性检验与评估

平方和分解 (Sum of Squares Decomposition)：回归分析的核心是将因变量的总波动进行拆解：

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

即：SST (总平方和) = SSR (回归平方和) + SSE (残差平方和)，SST 是数据总体的波动程度

SSR (Regression)：由自变量 X 的线性关系所解释的波动

SSE (Error/Residual)：未知随机误差带来的、未被解释的波动

拟合优度 R^2 (Coefficient of Determination) 定义： $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$ ；含义：自变量解释了因变量总波动幅度的百分之多少， $R^2 \in [0, 1]$ ，越接近 1 说明模型拟合得越好

修正 R^2 (Adjusted R^2)：在多元回归中，盲目增加无意义的自变量也会使 R^2 增大

为了消除变量个数的影响，引入自由度进行修正：

$$R_{adj}^2 = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)}$$

总体显著性检验 (F 检验)：原假设 $H_0: \beta_1 = \beta_2 = \cdots = \beta_p = 0$ (即所有自变量对 Y 都没有影响)

检验统计量：

$$F = \frac{SSR/p}{SSE/(n-p-1)} \sim F(p, n-p-1)$$

决策：若 $F > F_{1-\alpha}(p, n-p-1)$ ，则拒绝原假设，说明回归方程整体是显著的。单个系数的显著性检验

(t 检验)：原假设 $H_0: \beta_j = 0$ (第 j 个自变量对 Y 没有独立显著影响)。检验统计量：

$$t = \frac{\hat{\beta}_j - 0}{se(\hat{\beta}_j)} \sim t(n-p-1)$$

其中 $se(\hat{\beta}_j)$ 是回归系数的标准误。若 $|t| > t_{1-\alpha/2}(n-p-1)$ ，则拒绝 H_0 ，说明该自变量是显著的

模型诊断与多重共线性

异常现象与诊断工具：残差图 (Residual Plot)：用于检查方差齐性和线性。若残差随拟合值增大呈喇叭状，说明存在异方差性；若残差有明显的二次曲线趋势，说明遗漏了二次项，非线性。多重共线性 (Multicollinearity)：概念：多元回归中，自变量之间存在高度线性相关。后果：会导致 $(\mathbf{X}^T \mathbf{X})^{-1}$ 接近奇异矩阵，使得参数估计值的方差急剧变大， t 检验失效（表现为 F 检验显著，但所有单个 t 检验都不显著）
诊断指标：方差膨胀因子 (VIF, Variance Inflation Factor)。当某个变量的 $VIF > 10$ 时，说明存在严重的共线性问题，需要剔除变量或采用岭回归 (Ridge)

例（房屋价格预测与模型分析）：某研究收集了 20 套房屋的销售数据，欲研究房屋售价 (Y , 单位：万元) 与建筑面积 (X_1 , 单位：平方米) 及卧室数量 (X_2 , 单位：个) 之间的关系。经过计算，模型拟合的矩阵计算结果和 ANOVA (方差分析) 表部分数据如下：样本量 $n = 20$ ，自变量个数 $p = 2$ 。得到的估计方程为： $\hat{Y} = 50 + 1.2X_1 + 15X_2$ 。已知总平方和 $SST = 12000$ ，残差平方和 $SSE = 2000$

问：请计算回归平方和 SSR 以及该模型的拟合优度 R^2 与修正 R^2

问：写出总体显著性检验 (F 检验) 的原假设、备择假设，并计算 F 统计量的值

问：如果 X_1 的系数标准误 $se(\hat{\beta}_1) = 0.3$ ，请对面积变量进行单个系数的显著性检验 ($\alpha = 0.05$)，已知临界值 $t_{0.975}(17) = 2.11$

解：计算平方和与拟合优度计算 SSR ：根据平方和分解公式 $SST = SSR + SSE$ ：

$$SSR = SST - SSE = 12000 - 2000 = 10000$$

计算 R^2 ：

$$R^2 = \frac{SSR}{SST} = \frac{10000}{12000} \approx 0.8333 \quad (83.33\%)$$

表明房屋售价 83.33% 的变动可以由建筑面积和卧室数量来线性解释。计算修正 R^2 (R_{adj}^2)：已知 $n = 20, p = 2$ 。

$$R_{adj}^2 = 1 - \frac{SSE/(n-p-1)}{SST/(n-1)} = 1 - \frac{2000/(20-2-1)}{12000/(20-1)}$$

$$R_{adj}^2 = 1 - \frac{2000/17}{12000/19} = 1 - \frac{117.65}{631.58} = 1 - 0.1863 = 0.8137$$

解：总体显著性 F 检验假设建立： $H_0 : \beta_1 = \beta_2 = 0$ （面积和卧室数量对房价均无线性影响） $H_1 : \beta_1, \beta_2$ 至少有一个不为 0；计算 F 统计量：

$$F = \frac{SSR/p}{SSE/(n-p-1)} = \frac{10000/2}{2000/17} = \frac{5000}{117.65} \approx 42.50$$

结论判断：在给定的显著性水平下，由于 $F = 42.50$ 非常大（远大于常规临界值），因此拒绝原假设 H_0 ，回归方程整体非常显著

解：系数 β_1 的 t 检验假设建立： $H_0 : \beta_1 = 0$ （控制其他变量不变时，建筑面积对房价没有独立显著影响） $H_1 : \beta_1 \neq 0$ ；计算 t 统计量：已知 $\hat{\beta}_1 = 1.2$ ， $se(\hat{\beta}_1) = 0.3$ ：

$$t = \frac{\hat{\beta}_1 - 0}{se(\hat{\beta}_1)} = \frac{1.2}{0.3} = 4.00$$

结论判断：计算出的 $|t| = 4.00$ 。对比题目给出的临界值 $t_{0.975}(17) = 2.11$ 。因为 $|t| = 4.00 > 2.11$ ，所以拒绝原假设，即：建筑面积对房屋售价的线性影响在 0.05 的水平下是高度显著的

必背公式： $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$

自由度分配： SSR 自由度是 p （自变量个数）， SSE 自由度是 $n - p - 1$ ， SST 自由度是 $n - 1$ 。多元线性回归系数是偏回归系数，解释时必须加上“在控制其他自变量不变的条件下”这一前提

集中看例题和模拟题

选择题一些概念

样本量增大则均数的标准差（标准误）变小， $SE = \frac{\sigma}{\sqrt{n}}$ ，样本量不影响均数本身期望（= 总体均数 μ ）

注意个体值分布的 95% 参考值范围是 $\bar{X} \pm 1.96 * S$ ，参考值范围是判断个体，置信区间是估计总体参数

线性变换对均数和标准差的影响， $X + c$ 对应均数变为 $\bar{X} + c$ ，标准差不变（+20，均 520 标 100）

线性变换对均数和标准差的影响， $X \times k$ 对应均数变为 $\bar{X} \times k$ ，标准差 $S \times k$ （ $\times 20\%$ ，均 600 标 120）

所有观测值减去同一常数，两组均数差不变、标准差不变、t 统计量不变， $t = \frac{\bar{X}_1 - \bar{X}_2}{S_c \sqrt{1/n_1 + 1/n_2}}$

二项分布 $X \sim B(n, p)$ 的正态近似均值 $\mu = np$ 方差 $\sigma^2 = np(1-p)$ ，标准化 $Z = \frac{X - np}{\sqrt{np(1-p)}}$

标准正态曲线下的面积 $z_{0.0975} \approx 1.96$ ，从 0 到 1.96 的面积 $\text{pnorm}(1.96) - \text{pnorm}(0) = 0.475$

从负无穷到 1.96 是 0.975 记好了

样本量估算，首先有估计总体率的公式 $n = \frac{z_{\alpha/2}^2 \cdot p(1-p)}{d^2}$ ，其中 d 是绝对误差，若给相对误差 r ，则 $d = r \times p$

给原题：普遍患病率 10%，单纯随机抽样调查患病率，95% 置信度，相对误差不超过 20%

解有 $d = r \times p = 0.2 \times 0.1 = 0.02$ ， $n = \frac{1.96^2 \times (0.1 \times 0.9)}{0.02^2} = 864.36$

相关系数 r 没有量纲，不会受单位变化影响；但回归系数 $b = r \frac{S_y}{S_x}$ 会随单位改变；t 检验统计量有关单位

泊松分布和二项分布的关系： $B(n, p) \xrightarrow{n \rightarrow \infty, p \rightarrow 0} \text{Poisson}(\lambda = np)$

注意二项分布的均值永远大于等于方差，等号仅在 $p=0$ 或 $n=0$ 时成立（此时方差为 0）

据文献，传统疗效均数 2.3 标准差 1.8，新药疗效均数 2.9 标准差 1.4， $\alpha = 0.05$ ， $\text{power} = 80\%$

均衡设计单组样本量 $n = \frac{2(z_{1-\alpha/2} + z_{1-\beta})^2 \sigma^2}{\delta^2}$

其中效应差值 $\delta = 2.9 - 2.3 = 0.6$ ，合并方差 $\sigma^2 = \frac{1.8^2 + 1.4^2}{2} = 2.6$ ，正态分布 $z_{0.975} = 1.96$ ， $z_{0.8} = 0.84$

$z_{0.975} = \text{qnorm}(0.975, \text{mean} = 0, \text{sd} = 1) = 1.96$ ， $z_{0.8} = \text{qnorm}(0.8, \text{mean} = 0, \text{sd} = 1) = 0.84$

算得 $n = \frac{2.6 \times 2 \times (1.96 + 0.84)^2}{0.6^2} = 113.24$

给出 60 名患者术后 1 年内死亡 10 例，两年内死亡 20 例，3 年内死亡 30 例；概率 = 1-两年存活概率

$P(\text{活 2 年}) = \frac{50}{60} \times \frac{40}{50} = \frac{40}{60}$ ； $P(\text{2 年内死亡}) = 1 - \frac{40}{60} = \frac{20}{60}$

已知治愈率 $p_0 = 0.25$ ，单侧检验，新药是否优于标准： $H_0: p \leq 0.25$ ， $H_0: p > 0.25$ ，做正态近似

$\frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} \geq z_{0.95} \approx 1.645$ ；设要治愈 h 人， $\hat{p} = h/300$ ：解 $\frac{h/300 - 0.25}{\sqrt{0.25 \times 0.75/300}} \geq 1.645$ ，得 $h \geq 87.34$

一个盒子中装有 10 个大小、形状完全相同的晶体管，其中 4 只是次品，按下列两种方法抽晶体管：

(1) 先任取一只，作测试后放回盒中，再任取下一只

(2) 先任取一只，作测试后不放回，在剩下的中再任取一只

试分别对这两种抽样方法，求从这 10 只球任取 3 只中，恰有 1 只是次品的概率

解 (1)：伯努利？抽三次每次独立事件 $P = \binom{3}{1} (4/10)^1 (6/10)^2 = 3 \times \frac{144}{1000} = 0.432$

解 (2)：古典概型不放回的 $P = \frac{{}_6C_2 \times {}_4C_1}{{}_{10}C_3} = \frac{60}{120} = 1/2$

```
> choose(10, 3)
[1] 120
> choose(6, 2)
[1] 15
> choose(4, 1)
[1] 4
```

设有 $X \sim \text{Binom}(n = 1000, p = 0.2)$, 求 $P(166 < X < 233)$

解: n 够大所以能用正态分布近似, 有 $X \approx N(\mu = np, \sigma^2 = np(1-p)) \equiv N(200, 160)$

下限标准化, $Z = \frac{X-\mu}{\sigma} = \frac{166-200}{\sqrt{160}} \sim N(0, 1)$; 上限类似, $\frac{233-200}{\sqrt{160}} \sim N(0, 1)$

区间概率 $P(166 < X < 233) = \Phi(\frac{233-200}{\sqrt{160}}) - \Phi(\frac{166-200}{\sqrt{160}})$

```
mu <- 1000 * 0.2
sigma <- sqrt(1000 * 0.2 * 0.8) # sqrt(160)

z_lower <- (166 - mu) / sigma
z_upper <- (233 - mu) / sigma

prob_norm <- pnorm(z_upper) - pnorm(z_lower)
print(prob_norm)
```

逻辑回归输出的是事件发生概率 p , 而并非直接预测 y 值, 即 $\text{logit}(p) = \ln(\frac{p}{1-p}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$, 变换可得概率 $p = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3}}$; 根据下面的输出结果得什么样的回归公式?

解: $\ln(\frac{\hat{p}}{1-\hat{p}}) = 0.59 - 1.49x_1 - 0.001x_2 + 0.31x_3$

从下面结果能看出 x_1 是显著的, 对应检验统计量 $z = \frac{\text{Estimate}-0}{\text{Std.Err}} = \frac{-1.496084}{0.704861} = -2.123$

在原假设 $H_0: \beta_1 = 0$ 下, $z \sim N(0, 1)$, $p = 0.0338$ 说明有 3.38% 的概率观察到如此极端的结果
比较多个模型的时候 AIC 越小模型越好, 简化模型则去掉后两个变量然后再次做拟合, 一样的
`fit.full_re <- glm(y ~ x1, data = drivers, family = binomial)`

`summary(fit.full_re)`

简化模型的 AIC 如果变小则模型更好, 再做 ANOVA 看它和全模型比有没有显著拟合上的差异
Resid.Dev (残差偏差): 越小表示模型拟合越好

Deviance = 57.241 - 57.026 = 0.215 (两个模型的偏差之差)

Pr(> Chi) = 0.8978: p 值很大, 不拒绝原假设

原假设: 简化模型 (去掉 x_2, x_3) 与全模型没有显著差异

结论: $p=0.8978 > 0.05$, 说明去掉 x_2 和 x_3 不会显著降低模型拟合效果, 因此简化模型更优

检验统计量: $D = \text{Deviance}_{\text{reduced model}} - \text{Deviance}_{\text{full model}} \sim \chi^2(df\text{-之差})$

本题 df 差 = 2, 因为减掉两个变量, $p = 1 - \text{pchisq}(0.21572, 2) \approx 0.8978$

```
drivers<-read.csv("./data/Drivers.csv", header = T, sep = ",")
fit.full<-glm(y~x1+x2+x3, data=drivers, family=binomial)
summary(fit.full)

## glm(formula = y ~ x1 + x2 + x3, family = binomial, data = drivers)
##
## Deviance Residuals:
## Min 1Q Median 3Q Max
## -1.5636 -0.9131 -0.7892  0.9637  1.6000
##
## Coefficients:
## Estimate Std. Error z value Pr(>|z|)
## (Intercept)  0.597610  0.894831  0.668  0.5042
## x1 -1.496084  0.704861 -2.123  0.0338 * # 显著
## x2 -0.001595  0.016758 -0.095  0.9242   # 不
## x3  0.315865  0.701093  0.451  0.6523   # 不
```

```
## (Dispersion parameter for binomial family taken to be 1)
## Null deviance: 62.183 on 44 degrees of freedom
## Residual deviance: 57.026 on 41 degrees of freedom
## AIC: 65.026
## Number of Fisher Scoring iterations: 4

fit.full_re<-glm(y~x1,data = drivers,family = binomial)
summary(fit.full_re)

## glm(formula = y ~ x1, family = binomial, data = drivers)
##
## Deviance Residuals:
## Min 1Q Median 3Q Max
## -1.4490 -0.8782 -0.8782  0.9282  1.5096
##
## Coefficients:
## Estimate Std. Error z value Pr(>|z|)
## (Intercept)  0.6190  0.4688  1.320  0.1867
## x1 -1.3728  0.6353 -2.161  0.0307 *

## Null deviance: 62.183 on 44 degrees of freedom
## Residual deviance: 57.241 on 43 degrees of freedom
## AIC: 61.241
## Number of Fisher Scoring iterations: 4

anova(fit.full, fit.full_re, test = "Chisq")

## Model 1: y ~ x1 + x2 + x3
## Model 2: y ~ x1
##   Resid. Df  Resid. Dev   Df   Deviance  Pr(>Chi)
## 1      41      57.026    -2    -0.21572    0.8978
## 2      43      57.241
```


代码

数据导入

```
data <- read.table('文档.txt', header = TRUE)
mnist <- read.csv("mnist_train.csv", header = TRUE)
head(data)
```

数据质量控制

1. 剔除缺失值比例大于 50% 的列
2. 剔除零方差（常数变动）特征，2 表示按列操作（1 表示按行）
3. 缺失值均值填补
4. 数据标准化（使均值为 0，方差为 1），消除量纲影响

```
missing_ratio <- colMeans(is.na(data)) # 1
data_cleaned <- data[, missing_ratio < 0.5]

variances <- apply(data_cleaned, 2, var, na.rm = TRUE) # 2
data_cleaned <- data_cleaned[, variances > 0]

for(i in 1:ncol(data_cleaned)) { # 3
  if(any(is.na(data_cleaned[,i]))) {
    data_cleaned[is.na(data_cleaned[,i]), i] <- mean(data_cleaned[,i], na.rm = TRUE)
  }
}

data_scaled <- scale(data_cleaned) # 4
```

古典概型 52 张牌抽 2 张全是黑桃： $(_{13}C_2)/(_{52}C_2)$ ； $\binom{n}{k} = \frac{n!}{k!(n-k)!}$

```
prob_poker <- choose(13, 2) / choose(52, 2) # nCk
```

二项分布 $X \sim \text{Bino}(n, p)$ ，公式 $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$

给出某个分布的参数：n = 5000，p = 0.1；

- (1) 求 $P(X > 500)$ ； (2) 求恰好等于 500 的概率 $P(X = 500)$

- (1) 直接算 $P(X > 500) = \sum_{k=501}^{5000} \binom{5000}{k} (0.1)^k (0.9)^{5000-k}$ ； $P(X \leq 500) = \sum_{k=0}^{500} \binom{5000}{k} (0.1)^k (0.9)^{5000-k}$
还可以根据中心极限定理用正态近似，其中 $\mu = 500$ ， $\sigma = \sqrt{np(1-p)} = \sqrt{5000*0.1*0.9} = 21.21$
 $P(X > 500) = P\left(Z > \frac{500-500}{21.21}\right) = P(Z > 0) = 0.476$

R 中四种概率函数的缩写前缀：

- d(density, pmf): 求恰好等于某值的概率（离散点概率）
- p(distribution function): 求累积概率（至多/至少/大于）
- q(quantile function): 求分位数（已知概率求临界值值）
- r(random numbers): 生成随机数

(2) 注意了

`pbinom(500,size = 5000,prob = 0.1)` 算的是 $P(X \leq 500)$ 累积概率

`pbinom(500,5000,0.1,lower.tail = FALSE)` 算的是 $P(X > 500)$

`ppois(60,lambda = 5)` 算的是 $P(X \leq 60)$

`pnorm(-1.96)` 算的是 $P(Z \leq -1.96) = 0.0249979$

`pnorm(1.96)` 算的是 $P(Z \leq 1.96) = 0.9750021$

`pnorm(85,mean = 80,sd = 5)` 算的是成绩 85 以下的占比, 累计概率, 负无穷到 x 的面积

`pnorm(5,mean = 3,sd = 2) - pnorm(2,mean = 3,sd = 2)` 算的是区间概率, $P(2 < X < 5)$

`dbinom(500,size = 5000,prob = 0.1)` 算的是 $P(X = 500)$ 精确的概率, 恰好等于

`dnorm(x,mean = 0,sd = 1)` 算的是密度函数值

`dpois(60,lambda = 5)` 算的是 $P(X = 60)$ 恰好等于

`qbinom(500,size = 5000,prob = 0.1)` 算的是第 95% 分位数

`qpois(0.95,lambda = 5)` 算的是第 95% 分位数

`qnorm(0.975) = 1.959964` 算的是标准正态分布的 97.5% 分位数 (双侧 95% 置信区间用)

`qnorm(0.95,mean = 0,sd = 1) = 1.645` 算的是单侧双侧 95% 临界值

`rpois(100,lambda = 5)` 生成一百个随机数 (符合泊松分布)

`rexp(100,rate = 0.5)` 生成一百个随机数 (符合指数分布), 密度函数 `dexp(x,rate = 0.5)`

```
pbinom(500, size = n, prob = p, lower.tail = FALSE) # (1)
dbinom(500, size = n, prob = p) # (2)
```

常用分布关系

卡方 + 指数/Gamma: $\chi^2(n) \equiv \Gamma(n/2, 1/2)$; $\chi^2(2) \equiv \Gamma(1, 1/2)$; X 服从指数分布时 $2\lambda X \sim \chi^2(2)$

卡方分布可加性: $\chi^2(n_1) + \chi^2(n_2) \sim \chi^2(n_1 + n_2)$

指数 + Gamma: $Exp(\lambda) \equiv \Gamma(1, \lambda)$; $\sum_{i=1}^n Exp(\lambda) \sim \Gamma(n, \lambda)$

泊松分布 $Z \sim Poisson(\lambda)$, 公式 $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$

λ 较大的时候可用大样本正态近似, 有双侧 95% 置信区间推导:

$$P\left(-1.96 \leq \frac{Z - \lambda}{\sqrt{\lambda}} \leq 1.96\right) \approx 0.95$$

设观察到 $obs = 220$ (用观测到的计数代替 λ), 求 $X \sim Poisson(\lambda)$ 里 λ 的 95% 置信区间

作业题推导 $\frac{(obs - \lambda)^2}{\lambda} \leq z_{\alpha/2}^2 = (obs - \lambda)^2 = z_{\alpha/2}^2 \cdot \lambda$

拆开 $\lambda^2 - (2obs + z^2)\lambda + obs^2 = 0$, 解得 $\lambda = \frac{2obs + z^2 \pm \sqrt{(2obs + z^2)^2 - 4obs^2}}{2} = (obs + \frac{1}{2}z^2) \pm z\sqrt{obs + \frac{z^2}{4}}$

```
obs <- 220
z <- qnorm(0.975) # 1.959964
ci_lower <- obs + (z^2)/2 - z_val * sqrt(obs + (z^2)/4)
ci_upper <- obs + (z^2)/2 + z_val * sqrt(obs + (z^2)/4)
```

指数分布 $X \sim Exp(\lambda)$, 公式 $f(x) = \lambda e^{-\lambda x}$, 重要性质: $2\lambda \sum_{i=1}^n X_i \sim \chi^2(2n)$ ($X_1, X_2, \dots, X_n \sim Exp(\lambda)$)

对于指数分布, 有 $X_i \sim Exp(\lambda)$ 等同于 $2\lambda X_i \sim \chi^2(2)$, 注意 $\chi^2(2)$ 等同于参数为 1/2 的指数分布

证: 若随机变量 X 有密度函数 $p_X(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} I_{x>0}$ ($\alpha > 0, \beta > 0$), 则 X 服从 Γ 分布 $\Gamma(\alpha, \beta)$

当 $\Gamma(\alpha, \beta)$ 的参数 $\alpha = 1, \beta = \lambda$ 时, X 服从参数为 λ 的指数分布

设有一组随机变量 $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda) \equiv \Gamma(1, \lambda)$, 对连续型随机变量 X ,

当 $Y = kX + b$ 为单调函数时, Y 的密度函数为 $p_Y(y) = p_X(g(y))|g'(y)|$, 其中 $g(y) = x = \frac{y-b}{k}$ 为反函数

设 $Y_i = 2\lambda X_i$, 则有 $g(y) = \frac{y}{2\lambda}$, 以及 $p_{Y_i}(y) = \lambda e^{-\lambda(\frac{y}{2\lambda})} \left| \frac{1}{2\lambda} \right| = \frac{1}{2} e^{-\frac{1}{2}y}$ (说明 Y_i 服从参数为 $\frac{1}{2}$ 的指数分布)

也就是 $Y_1, Y_2, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} \Gamma(1, \frac{1}{2})$, 因为这些分布的尺度参数 β 相同, 满足 Γ 分布可加性

(可加性: $X \sim \Gamma(\alpha_1, \beta), Y \sim \Gamma(\alpha_2, \beta), X + Y \sim \Gamma(\alpha_1 + \alpha_2, \beta)$), 有 $2\lambda \sum_{i=1}^n X_i = \sum_{i=1}^n Y_i \sim \Gamma(n, \frac{1}{2})$;

如果随机变量 $X \sim \Gamma(\frac{n}{2}, \frac{1}{2})$, 则 X 服从自由度为 n 的卡方分布

再因为自由度为 $2n$ 的卡方分布和 $2\lambda \sum_{i=1}^n X_i$ 所服从的 Γ 分布对应的密度函数相同,

都是 $p_{2\lambda \sum X_i}(x) = \frac{(1/2)^n}{\Gamma(n)} (x)^{n-1} e^{-\frac{1}{2}x} I_{x>0}$, 因此可证 $2\lambda \sum_{i=1}^n X_i$ 服从自由度为 $2n$ 的卡方分布,

即 $2\lambda \sum_{i=1}^n X_i \sim \Gamma(n, \frac{1}{2}) \equiv \chi^2(2n)$ 。

注意独立卡方变量之和服从卡方分布, 自由度相加, $X \sim \chi^2(n), Y \sim \chi^2(m), X + Y \sim \chi^2(n + m)$

有 $2\lambda \sum_{i=1}^n X_i = \sum_{i=1}^n (2\lambda X_i) \sim \chi^2(2n)$

设 $S = \sum_{i=1}^n X_i$, 有 $2\lambda S \sim \chi^2(2n)$, 以及 $P(\chi_{\alpha/2}^2(2n) \leq 2\lambda S \leq \chi_{1-\alpha/2}^2(2n)) = 1 - \alpha$

且有 λ 的区间 $P(\frac{\chi_{\alpha/2}^2(2n)}{2S} \leq \lambda \leq \frac{\chi_{1-\alpha/2}^2(2n)}{2S}) = 1 - \alpha$; λ 的置信区间: $(\frac{\chi_{\alpha/2}^2(2n)}{2 \sum X_i} \leq \lambda \leq \frac{\chi_{1-\alpha/2}^2(2n)}{2 \sum X_i})$

```
set.seed(123)
X <- rexp(500, rate = 0.5) # random nums from $Exp(λ=0.5)$
n <- length(X); sum_x <- sum(X)

chi_lower <- qchisq(0.025, df = 2 * n)          # λ's 95% CI
chi_upper <- qchisq(0.975, df = 2 * n)

lambda_ci <- c(chi_lower / (2 * sum_x), chi_upper / (2 * sum_x))
```

正态分布均值的置信区间, 方差未知用 t 分布

$X \sim N(\mu, \sigma^2)$, 样本均值 $\bar{X}$ 和标准差 S , 有总体均值的 $(1 - \alpha)$ 置信区间 $\bar{X} \pm t_{1-\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}}$

算这个 $t_{1-\frac{\alpha}{2}, n-1}$ 用 $qt(0.975, df = n - 1)$

```
some_random_x <- rnorm(30, mean = 10, sd = 2)
t.test(some_random_x)\$conf.int

# 手算
mean_x <- mean(some_random_x); SE <- sd(some_random_x) / sqrt(length(some_random_x))
ci_lower <- mean_x - qt(0.975, df = length(some_random_x)-1) * SE
ci_upper <- mean_x + qt(0.975, df = length(some_random_x)-1) * SE
```

二项分布比例 p 的置信区间 (Wilson 得分区间, 比 Wald 区间更精确尤其 p 接近 0 或 1 时)

Wilson 区间是通过解这个不等式得到的 (正态近似): $\frac{\hat{p}-p}{\sqrt{p(1-p)/n}} \leq z_{1-\alpha/2}$

```
library(Hmisc)
binconf(x = 60, n = 100, method = "wilson") # 60 SUCCESSES out of 100 TOT TRIALS
# PointEst Lower Upper
# 0.6 0.498 0.694
```

卡方检验用于分类变量, H_0 : 两个变量独立, 无关联

应用场景: 比较两个分类变量是否独立 (如吸烟和患病), 检验统计量: $\chi^2 = \sum \frac{(O-E)^2}{E} \sim \chi^2(r-1)(c-1)$

```
# 列联
table_data <- matrix(c(30, 10, 15, 25), nrow = 2, byrow = TRUE)
chisq.test(table_data, correct = FALSE) # correct = FALSE, No Yates Continuity Correc
```

单总体, 指数分布, 假设检验: $H_0: \lambda = \lambda_0 = 0.5$, $H_1: \lambda \neq 0.5$; 检验统计量: $T = 2\lambda_0 \sum_i^n X_i \sim \chi^2(2n)$

```
T_stat <- 2 * 0.5 * sum_x

chi_lower = qchisq(0.025, 2n)
chi_upper = qchisq(0.975, 2n)

if (T_stat < chi_lower || T_stat > chi_upper) {
  print("拒")
} else {
  print("接")
}
```

两个正态总体的方差齐性检验 (F 检验): $H_0: \sigma_1^2 = \sigma_2^2$, $H_1: \sigma_1^2 \neq \sigma_2^2$

注意方差齐性是独立样本 t 检验、方差分析 ANOVA 的前提条件; 检验统计量: $F = \frac{S_1^2}{S_2^2} \sim F(n_1-1, n_2-1)$

方法一用 `qf`, 默认 `alternative = 'two.sided'`, 若问 A 方差是否大于 B, 改用 '`greater`'

方法二是结合 F 分布手动计算 95% 置信区间

```
# 1
var.test(X1, X2, alternative = 'two.sided')

# 2
s1_sq <- var(X1); s2_sq <- var(X2)
ratio <- s1_sq / s2_sq

f_lower <- qf(0.025, df1 = length(X1)-1, df2 = length(X2)-1)
f_upper <- qf(0.975, df1 = length(X1)-1, df2 = length(X2)-1)

CI <- c(ratio / f_upper, ratio / f_lower)
```

两个独立样本的 t 检验, 方差未知但是相等, 检验均值: $H_0: \mu_1 = \mu_2$, $H_1: \mu_1 \neq \mu_2$

另有左侧单侧检验: $H_0: \mu_1 \geq \mu_2$, $H_1: \mu_1 < \mu_2$; 右侧单侧检验: $H_0: \mu_1 \leq \mu_2$

检验统计量: $t = \frac{\bar{X}_1 - \bar{X}_2}{S_c \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2)$, 其中联合方差 $S_c^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}$

适用条件: 两样本相互独立, 方差齐性, 且来自于正态分布总体

(方差不等的时候计算的统计量要改为 Satterthwaite 近似 $t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{S_1^2/n_1 + S_2^2/n_2}} \sim t(n_1 + n_2 - 2)$)

单侧检验, 左侧备择 $H_1: \mu_1 < \mu_2$, 检验是否小用 `alternative = 'less'`, 是否大用 '`greater`'

```
# var.equal = TRUE,  $\sigma^2$  齐性
t.test(X1, X2, var.equal = TRUE, alternative = "two.sided")
```

单样本 t 检验, 假设 $H_0: \mu = \mu_0$, 双侧 $H_1: \mu \neq \mu_0$, 检验统计量: $t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$

适用条件: 样本来自正态总体 (或者样本量很大) 且方差未知

应用场景: 比较样本均值是否与已知均值有显著差异

```
data_vector <- c(125, 128, 130, 122, 127, 129, 126, 124)
data_vector <- my_data$blood_pressure
data_vector <- rnorm(30, mean = 120, sd = 5)

t.test(data_vector, mu = 12345, alternative = "two.sided")
# alternative = "greater" (H0:  $\mu_1 \leq \mu_2$ , H1:  $\mu_1 > \mu_2$ )
# alternative = "less" (H0:  $\mu_1 \geq \mu_2$ , H1:  $\mu_1 < \mu_2$ )
```

单因素方差分析 One-way ANOVA, 假设 $H_0: \mu_1 = \mu_2 = \mu_3$, H_1 : 至少一组均值不同

适用条件: 独立性, 正态性, 方差齐性 (要做 Bartlett 或 Levene Test, Bartlett 对正态敏感, Levene 更稳健)

应用场景: 比较三个及以上!! 独立组的均值是否存在显著差异, 避免进行多次两样本 t 检验导致 I 类错

数据格式: 数值列 value (1 2 3 4 5) + 对应的分组列 group (A C B B A)

事后检验 (Tukey HSD) 可以找出具体哪些组不同, 因为 H_1 只是至少一组均值不同

```
the_data <- data.frame(
  group = c(rep("轻", times=9), rep("中", times=8), rep("重", times=7)),
  value = c(32, 43, 47, 57, 58, 59, 61, 72, 87,
            10, 25, 37, 40, 41, 48, 63, 70,
            7, 10, 16, 30, 43, 40, 57))

model <- aov(value ~ group, data = the_data)
summary(model)

# 事后
TukeyHSD(model)

# 齐性
bartlett.test(value ~ group, data = the_data)
car::leveneTest(value ~ group, data = the_data)
```

两因素方差分析 Two-way ANOVA, 假设 $H_0: \mu_1 = \mu_2 = \mu_3$, H_1 : 至少一组均值不同

适用条件: 独立性, 正态性, 方差齐性

应用场景: 比较三个及以上!! 独立组, 可分析两个因子 (如药物剂量 + 性别) 的主效应及交互效应
真的会考吗, 不想学力

```
model2 <- aov(value ~ factor1 * factor2, data = the_data)
summary(model2)
```

数据处理用

剔除缺失率大于百分之五十以上的列: `data[, colMeans(is.na(data)) < 0.5]`

剔除 0 方差的列: `data[, apply(data, 2, var, na.rm = TRUE) > 0]`

均值填补, 数据中第 i 列里那些缺失的行替换成该列已有的非缺失值的均值

`data[is.na(data[, i]), i] <- mean(data[, i], na.rm = TRUE)`

z-score 标准化: `scale(data)`

常见分布的概率计算用

二项分布 $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$

`dbinom(k, n, p)`, n 次独立伯努利试验中, 每次成功的概率为 p , 恰好成功 k 次的概率

`binom(x, n, p)`, 累积概率 $P(X \leq x)$

`binom(x, n, p, lower.tail = FALSE)`, 上尾概率 $P(X > x) = 1 - P(X \leq x)$

`qbinom(0.95, n, p)`, 分位数 $P(X \leq x) = 0.95$ 对应的 x

泊松分布 $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$

`dpois(k, lambda)`

指数分布 $f(x) = \lambda e^{-\lambda x}$, $x > 0$

`dexp(x, rate = lambda)`

正态分布 $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

`dnorm(x, mean, sd)`

`qnorm(0.975)`, 标准正态分位数 $z_{\alpha/2} \approx 1.96$

`qt(0.975, df = n - 1)`, t 分布分位数 $t_{\alpha/2, n-1}$

`qt(0.95, df = n - 1)`, 单侧 t 临界值 (右侧单侧检验 $\alpha=0.05$)

正态分布均值 μ 的置信区间 (σ 未知), $\bar{x} \pm t_{0.975, n-1} \frac{s}{\sqrt{n}}$

生成随机数: `rbinom(100, n, p)`

假设检验用

单样本 t 检验, 统计量: $t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n - 1)$

`t.test(x, mu = mu0)`

两样本 t 检验, 等方差, 统计量: $t = \frac{\bar{X}_1 - \bar{X}_2}{S_c \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2)$

`t.test(x, y, var.equal = TRUE)`

两样本 t 检验, 不等方差, 统计量: t 用 Satterthwaite 近似算

`t.test(x, y) (Welch)`

方差齐性检验, F 检验, 统计量: $F = \frac{S_1^2}{S_2^2} \sim F(n_1 - 1, n_2 - 1)$

`var.test(x, y)`

单因素 ANOVA, 统计量: $F = \frac{MS_{between}}{MS_{within}}$

`aov(y ~ group, data)`, 以及事后两两比较 `TukeyHSD(aov_fit)`

卡方独立性检验和拟合优度检验, 统计量: $\chi^2 = \sum \frac{(O-E)^2}{E} \sim \chi^2(r - 1)(c - 1)$

`chisq.test(table, correct = FALSE)`

`chisq.test(x, p = expected_probs)`

回归分析用

简单线性回归, $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$: `lm(y ~ x, data)`

多元线性回归, $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$: `lm(y ~ x1 + x2, data)`
 模型摘要: `summary(lm_fit)`
 系数的置信区间, $\hat{\beta}_j \pm t_{0.975, (n-p-1)} \cdot SE(\hat{\beta}_j)$: `confint(lm_fit)`
 预测 $\hat{y}_{new}$: `predict(lm_fit, new_data)`, 残差诊断用 `plot(lm_fit)`

分类模型

逻辑回归, 二分类输出概率: `glm(y ~ x, family = binomial, data)`
 线性判别分析 LDA, 线性分类边界: `lda(Label ~ ., data)`
 朴素贝叶斯, 假设特征独立: `naiveBayes(Label ~ ., data)`
 支持向量机 SVM, 核技巧, 低维数据隐式地映射到高维特征空间: `ksvm(Label ~ ., data, kernel = 'rbfdot')`
 决策树 CART: `rpart(Label ~ ., data, method = 'class')`
 随机森林, 集成学习: `randomForest(Label ~ ., data, ntree = 500)`
 评价指标
`confusion_mat = table(pred, actual)`
`accuracy = sum(diag(conf_mat))/sum(conf_mat)`

无监督学习, 聚类和降维

K-means 划分聚类: `kmeans(data, centers = k, nstart = 24)`
 层次聚类, 树状图: `hclust(dist(data), method = 'ward.D2')`
 谱聚类, 图切割: `specc(as.matrix(data), centers = k)`
 高斯混合模型 GMM, EM 算法? 猜归属, 更参数, 交替迭代, 收敛至局部最优: `Mclust(data, G = k)`
PCA: `princomp(data, cor = TRUE), prcomp(data, scale. = TRUE)`
`vars <- pca$sdev2`, 累计方差
`cum_var <- cumsum(vars/sum(vars))`, 前 k 个 PC 解释的方差比例
t-SNE 非线性降维: `Rtsne(data, dims = 2, perplexity = 30)`
SMOTE 不平衡数据处理
`library(smotefamily)`
`smote_res <- SMOTE(X_train, y_train, K = 5, dup_size = 2)`
`train_balanced <- smote_res$data`
 模型选择, 拟合优度 (似然) 和模型复杂度 (参数数量) 之间做权衡
`AIC(model)`, $AIC = -2\ln(L) + 2p$
`BIC(model)`, $BIC = -2\ln(L) + p\ln(n)$
 逐步回归 `step(model, direction = "both")`, 基于 AIC
caret 包带的交叉验证 `train(..., trControl = trainControl(method = "cv"))`

```
t.test(data_vector, mu = 0, alternative = "two.sided") # one sample t

fit <- aov(y ~ group, data = df) # one-way ANOVA
summary(fit)
TukeyHSD(fit)

Hmisc::binconf(x = success_n, n = total_n, method = "wilson") # binom Wilson CI
```



```
chisq.test(contingency_table, correct = FALSE)          # chi-square indep

mean_x <- mean(x); t_crit <- qt(0.975, df = n-1); se <- sd(x)/sqrt(n)
c(mean_x - t_crit * se, mean_x + t_crit * se)          # norm.dist  $\mu$ 's CI in t
```